

# DATA PREPROCESSING


PERBERSIHAN DATA (DATA CLEANING)

INTEGRASI DATA (DATA INTEGRATION)

TRANSFORMASI DATA (DATA TRANSFORMATION)

REDUKSI DATA (DATA REDUCTION)

## Tahapan Utama Proses Data Mining




## Input (Dataset)

- Dataset: (Data  
Record/point/vector/pattern/event/case)  
Kumpulan obyek data berserta
- atributnya.  
Atribut: (field/karakteristik, fitur)  
Sifat/property/karakteristik obyek data.

## Atribut, Class dan Tipe Data

- Atribut(variabel) adalah **faktor atau parameter yang menyebabkan** class/label/target terjadi
- Class adalah atribut yang akan dijadikan **target**, sering juga disebut dengan **label(AtributTarget)**
- Tipe data untuk variabel pada statistik terbagi menjadi empat: nominal, ordinal, interval, ratio
- Tapi secara praktis, tipe data untuk atribut pada data mining hanya menggunakan dua:
  1. **Nominal** (Kategorikal)
  2. **Numeric** (Kontinyu)

## Tipe Atribut



## Jenis Dataset


- Jenis dataset ada dua: **Private** dan **Public**
- **Private Dataset**: data set dapat diambil dari organisasi yang kita jadikan obyek penelitian
  - Bank, Rumah Sakit, Industri, Pabrik, Perusahaan, Jasa, etc
- **Public Dataset**: data set dapat diambil dari repositori publik yang disepakati oleh para peneliti data mining
  - UCI Repository (<http://www.ics.uci.edu/~mllearn/MLRepository.html>)
  - ACM KDD Cup (<http://www.sigkdd.org/kddcup/>)
- Trend penelitian data mining saat ini adalah menguji metode yang dikembangkan oleh peneliti dengan public dataset, sehingga penelitian dapat bersifat: **comparable**, **repeatable** dan **verifiable**

## Tipe Dataset

- Data Record
  - Data Matrix
  - Data Transaksi
  - Data Graph
- Data Terurut

|   | 1 | 2 | 3 | 4 | 5 | 6 |
|---|---|---|---|---|---|---|
| 1 | 0 | 1 | 1 | 0 | 0 | 1 |
| 2 | 1 | 0 | 1 | 1 | 0 | 1 |
| 3 | 1 | 1 | 0 | 1 | 1 | 0 |
| 4 | 0 | 1 | 1 | 0 | 1 | 0 |
| 5 | 0 | 0 | 1 | 1 | 0 | 1 |
| 6 | 1 | 1 | 0 | 0 | 1 | 0 |

| TID | Items                     |
|-----|---------------------------|
| 1   | Bread, Milk               |
| 2   | Bread, Diaper, Beer, Eggs |
| 3   | Milk, Diaper, Beer, Coke  |
| 4   | Bread, Milk, Diaper, Beer |
| 5   | Bread, Milk, Diaper, Coke |



## Kualitas Data

- Kesalahan Pengukuran: Nilai yg dicatat berbeda dg nilai sebenarnya (noise, bias, precision, accuracy)
- Kesalahan Pengumpulan: spt hilangnya obyek data/nilai dr atribut/lingkup obyek data yg tdk tetap
- Duplicate Data: obyek data ganda

## Kesalahan Pengumpulan

- **Outliers:** obyek data yg memiliki sifat yg berbeda sekali dari kebanyakan obyek data.
- **Missing Value:** nilai pd suatu atribut yg tdk ditemukan/kosong.
  - Bisa krn responden menolak memberikan informasi
  - Atribut tdk bisa diterapkan ke semua kasus
  - Diatasi dg mengurangi obyek data, memperkirakan missing value, mengganti dg nilai yg memungkinkan

**Attribute**

Class/Label

|     | Sepal Length (cm) | Sepal Width (cm) | Petal Length (cm) | Petal Width (cm) | Type                   |
|-----|-------------------|------------------|-------------------|------------------|------------------------|
| 1   | 5.1               | 3.5              | 1.4               | 0.2              | <i>Iris setosa</i>     |
| 2   | 4.9               | 3.0              | 1.4               | 0.2              | <i>Iris setosa</i>     |
| 3   | 4.7               | 3.2              | 1.3               | 0.2              | <i>Iris setosa</i>     |
| 4   | 4.6               | 3.1              | 1.5               | 0.2              | <i>Iris setosa</i>     |
| 5   | 5.0               | 3.6              | 1.4               | 0.2              | <i>Iris setosa</i>     |
| 51  | 7.0               | 3.2              | 4.7               | 1.4              | <i>Iris versicolor</i> |
| 52  | 6.4               | 3.2              | 4.5               | 1.5              | <i>Iris versicolor</i> |
| 53  | 6.9               | 3.1              | 4.9               | 1.5              | <i>Iris versicolor</i> |
| 54  | 5.5               | 2.3              | 4.0               | 1.3              | <i>Iris versicolor</i> |
| 55  | 6.5               | 2.8              | 4.6               | 1.5              | <i>Iris versicolor</i> |
| 101 | 6.3               | 3.3              | 6.0               | 2.5              | <i>Iris virginica</i>  |
| 102 | 5.8               | 2.7              | 5.1               | 1.9              | <i>Iris virginica</i>  |
| 103 | 7.1               | 3.0              | 5.9               | 2.1              | <i>Iris virginica</i>  |
| 104 | 6.3               | 2.9              | 5.6               | 1.8              | <i>Iris virginica</i>  |
| 105 | 6.5               | 3.0              | 5.8               | 2.2              | <i>Iris virginica</i>  |

### Estimasi Waktu Pengiriman Pizza

| Customer | Jumlah Pesanan | Jumlah Lampu Merah (L) | Jarak (J) | Waktu Tempuh (T) (P) |
|----------|----------------|------------------------|-----------|----------------------|
| 1        | 3              | 3                      | 3         | 16                   |
| 2        | 1              | 7                      | 4         | 20                   |
| 3        | 2              | 4                      | 6         | 18                   |
| 4        | 4              | 6                      | 8         | 36                   |
| ...      |                |                        |           |                      |
| 1000     | 2              | 4                      | 2         | 12                   |

$$\text{Waktu Tempuh (T)} = 0.48P + 0.23L + 0.5J$$


### Penentuan Kelulusan Mahasiswa

| NIM   | Gender | Nilai UN | Asal Sekolah | IPS1 | IPS2 | IPS3 | IPS 4 | ... | Lulus Tepat Waktu |
|-------|--------|----------|--------------|------|------|------|-------|-----|-------------------|
| 10001 | L      | 28       | SMAN 2       | 3.3  | 3.6  | 2.89 | 2.9   |     | Ya                |
| 10002 | P      | 27       | SMA DK       | 4.0  | 3.2  | 3.8  | 3.7   |     | Tidak             |
| 10003 | P      | 24       | SMAN 1       | 2.7  | 3.4  | 4.0  | 3.5   |     | Tidak             |
| 10004 | L      | 26.4     | SMAN 3       | 3.2  | 2.7  | 3.6  | 3.4   |     | Ya                |
| ...   |        |          |              |      |      |      |       |     |                   |
| ...   |        |          |              |      |      |      |       |     |                   |
| 11000 | L      | 23.4     | SMAN 5       | 3.3  | 2.8  | 3.1  | 3.2   |     | Ya                |

## Data Preprocessing

- ❑ **Data Preprocessing** merupakan tahapan/teknik paling awal sebelum melakukan proses data mining, dimana Data mentah akan diolah terlebih dahulu. Data Preprocessing atau praproses data biasanya dilakukan melalui cara eliminasi data yang tidak sesuai. Selain itu dalam proses ini data akan diubah dalam bentuk yang akan lebih dipahami oleh sistem.
- ❑ **Data preprocessing** adalah tahapan untuk menghilangkan beberapa permasalahan yang bisa mengganggu saat pemrosesan data. Hal tersebut karena banyak data yang formatnya tidak konsisten.
- ❑ Melalui data preprocessing, memungkinkan proses mining akan berjalan dengan lebih efektif dan efisien

## Data Preprocessing



## Mengapa Data Diproses Awal?

- Data dalam dunia nyata kotor
  - **Tak-lengkap**: nilai-nilai atribut kurang, atribut tertentu yang dipentingkan tidak disertakan, atau hanya memuat data agregasi
    - Misal, pekerjaan=""
  - **Noisy**: memuat error atau memuat outliers (data yang secara nyata berbeda dengan data-data yang lain)
    - Misal, Salary="-10"

## Mengapa Data Diproses Awal?

- **Tak-konsisten**: memuat perbedaan dalam kode atau nama
  - Misal, Age="42" Birthday="03/07/1997"
  - Misal, rating sebelumnya "1,2,3", sekarang rating "A, B, C"
  - Misal, perbedaan antara duplikasi record
- Data yang lebih baik akan menghasilkan data mining yang lebih baik
- Data preprocessing membantu didalam memperbaiki presisi dan kinerja data mining dan mencegah kesalahan didalam data mining.



## Mengapa Data Kotor?

- Ketaklengkapan data datang dari
  - Nilai data tidak tersedia saat dikumpulkan
  - Perbedaan pertimbangan waktu antara saat data dikumpulkan dan saat data dianalisa.
  - Masalah manusia, hardware, dan software
- Noisy data datang dari proses data
  - Pengumpulan
  - Pemasukan (entry)
  - Transmisi

## Mengapa Data Kotor?

- Ketak-konsistenan data datang dari
  - Sumber data yang berbeda
  - Pelanggaran kebergantungan fungsional

## Mengapa Pemrosesan Awal Data Penting?

- Kualitas data tidak ada, kualitas hasil mining tidak ada!
  - Kualitas keputusan harus didasarkan kepada kualitas data
    - Misal, duplikasi data atau data hilang bisa menyebabkan ketidak-benaran atau bahkan statistik yang menyesatkan.
  - Data warehouse memerlukan kualitas integrasi data yang konsisten
- Ekstraksi data, pembersihan, dan transformasi merupakan kerja utama dari pembuatan suatu data warehouse. — Bill Inmon

## Pengukuran Kualitas Data Multidimesi




- Kualitas data dapat diakses dalam bentuk:
  - Akurasi
  - Kelengkapan
  - Konsistensi
  - Ketepatan waktu
  - Kepercayaan
  - Nilai tambah
  - Penafsiran
  - Kemudahan diakses
- Kategori luas:
  - Hakekat, kontekstual, bisa direpresentasikan, dan mudah diakses

## Tugas Utama Pemrosesan Awal Data




- Pembersihan data (data yang kotor)
  - Mengisi nilai-nilai yang hilang, menghaluskan noisy data, mengenali atau menghilangkan outlier, dan memecahkan ketidak-konsistenan
- Integrasi data (data heterogen)
  - Integrasi banyak database, banyak kubus data, atau banyak file
- Transformasi data (data detail)
  - Normalisasi dan agregasi

## Tugas Utama Pemrosesan Awal Data



- Reduksi data (jumlah data yang besar)
  - Mendapatkan representasi yang direduksi dalam volume tetapi menghasilkan hasil analitikal yang sama atau mirip
- Diskritisasi data (kesinambungan atribut)
  - Bagian dari reduksi data tetapi dengan kepentingan khusus, terutama data numerik

## Bentuk-Bentuk Dari Pemrosesan Awal Data



## PEMBERSIHAN DATA (DATA CLEANING)

- Data cleaning adalah proses pembersihan dataset yang mencakup penghapusan data yang salah, tidak lengkap, tidak akurat, dll.
- Tujuan dari data cleaning adalah menyediakan sampel yang lengkap dan akurat untuk diproses lebih lanjut dalam data mining.
- Menurut Kepentingan Ralph Kimball, "Pembersihan data adalah salah satu dari 3 problem terbesar dalam data warehousing"
- Menurut DCI survey, "Pembersihan data adalah problem nomor 1 dalam data warehousing"
- Tugas pembersihan data
  - ✓ Mengisi nilai-nilai yang hilang
  - ✓ Mengenali outliers dan menghaluskan noisy data
  - ✓ Memecahkan redundansi yang disebabkan oleh integrasi data

## PEMBERSIHAN DATA (DATA CLEANING)

- Tugas pembersihan data
  - ✓ Mengisi nilai-nilai yang hilang
  - ✓ Mengenali outliers dan menghaluskan noisy data
  - ✓ Memecahkan redundansi yang disebabkan oleh integrasi data.
  - ✓ Memperbaiki ketidak-konsistenan data, US=USA?
    - Menggunakan rujukan eksternal
    - Mendeteksi pelanggaran kendala
      - Misal, kebergantungan fungsional

## Data Hilang

- Data tidak selalu tersedia
  - Misal, banyak tuple atau record tidak memiliki nilai yang tercatat untuk beberapa atribut, seperti customer income dalam data sales
- Hilangnya data bisa karena
  - Kegagalan pemakaian peralatan
  - Ketak-konsistenan dengan data tercatat lainnya dan karenanya dihapus
  - Data tidak dimasukkan karena salah pengertian
  - Data tertentu bisa tidak dipandang penting pada saat entry



## Data Hilang

- Tidak mencatat history atau tidak mencatat perubahan data
- Kehilangan data perlu disimpulkan

## Bagaimana Menangani Data Hilang?

- Mengabaikan tuple atau record: mudah tetapi tidak efektif, dan merupakan metoda terakhir
  - Biasanya dilakukan saat label kelas hilang
  - Tidak efektif bila persentasi dari nilai-nilai yang hilang per atribut sungguh-sungguh bervariasi.
- Mengisi nilai-nilai yang hilang secara manual:
  - Paling baik
  - Membosankan
  - Paling mahal biayanya
  - Tak mungkin dilakukan dalam banyak hal!

## Bagaimana Menangani Data Hilang?

- Mengisi nilai-nilai yang hilang secara otomatis menggunakan:
  - Suatu konstanta global: misal, “unknown”, “Null”, atau suatu kelas baru?!
    - Suatu pola yang memuat “unknown” atau “Null” adalah buruk
  - Gunakan rata-rata atribut
  - Pengempisan data ke mean/median
  - Rata-rata atribut untuk seluruh sampel yang masuk kedalam kelas yang sama
    - Lebih cerdas, dan suatu metoda yang baik


## Bagaimana Menangani Data Hilang?

- Nilai yang paling mungkin: berbasis inferensi seperti regresi, rumus bayesian, atau pohon keputusan
  - Klasifikasi untuk mendapatkan nilai yang paling mungkin
  - Suatu metoda yang baik dengan beberapa overhead
- Menggunakan suatu nilai untuk mengisi nilai yang hilang bisa membiaskan data, nilai bisa salah
- Nilai yang paling mungkin adalah yang terbaik
- Gunakan informasi yang paling banyak dari data yang ada untuk memprediksi

## Noisy Data


- Noise: error acak atau variansi dalam suatu variabel terukur
- Nilai-nilai atribut tak benar mungkin karena
  - Kegagalan instrumen pengumpulan data
  - Problem pemasukan data
  - Problem transmisi data
  - Keterbatasan teknologi
  - Ketak-konsistenan dalam konvensi penamaan
- Problem data lainnya yang memerlukan pembersihan data
  - Duplikasi record
  - Data tak lengkap
  - Data tidak konsisten

## Noisy Data: Menghilangkan Outlier





## Noisy Data: Penghalusan



## Bagaimana Menangani Noisy Data?


- Metoda Binning:
  - Pertama urutkan data dan partisi kedalam (kedalaman yang sama) bin-bin
  - Kemudian noisy data itu bisa dihaluskan dengan rata-rata bin, median bin, atau batas bin.
- Clustering
  - Medeteksi dan membuang outliers
- Inspeksi kombinasi komputer dan manusia
  - Mendeteksi nilai-nilai yang mencurigakan dan memeriksa dengan manusia (misal, berurusan dengan outlier yang mungkin)



## Bagaimana Menangani Noisy Data?

- Regresi
  - Menghaluskan dengan memasukkan data kedalam fungsi regresi

## Metoda Binning: Diskritisasi Sederhana



- Partisi **lebar yang sama** (jarak):
  - Membagi range kedalam N interval dengan ukuran yang sama: grid seragam
  - Jika  $A$  dan  $B$  masing-masing adalah nilai terendah dan tertinggi dari atribut, lebar interval akan menjadi :  $W = (B - A)/N$ .
  - Kebanyakan langsung, tetapi outlier mendominasi presentasi
  - Data Outlier dan menyimpang tidak ditangani dengan baik.

## Metoda Binning: Diskritisasi Sederhana

- Partisi **kedalaman sama** (frekuensi):
  - Membagi range kedalam  $N$  interval, masing-masing memuat jumlah sampel yang hampir sama
  - Penskalaan data yang baik
  - Penanganan atribut yang bersifat kategori bisa rumit.


## Metoda Binning Untuk Penghalusan Data

- Data terurut untuk harga (dalam dollar): 4, 8, 9, 15, 21, 21, 24, 25, 26, 28, 29, 34
- Partisi kedalam bin dengan kedalaman yang sama (misal, dalam bin-3):
  - Bin 1: 4, 8, 9, 15
  - Bin 2: 21, 21, 24, 25
  - Bin 3: 26, 28, 29, 34
- Haluskan dengan rata-rata bins:
  - Bin 1: 9, 9, 9, 9
  - Bin 2: 23, 23, 23, 23
  - Bin 3: 29, 29, 29, 29


## Metoda Binning Untuk Penghalusan Data

- Penghalusan dengan batas bin:
  - Bin 1: 4, 4, 4, 15
  - Bin 2: 21, 21, 25, 25
  - Bin 3: 26, 26, 26, 34

## Analisis Cluster



## Regresi



## Inspeksi Komputer dan Manusia Penghalusan

- Inspeksi kombinasi komputer dan manusia
  - Suatu ambang yang diberikan user
  - Komputer mendeteksi seluruh potensi outlier yang dikaitkan dengan ambang
  - Manusia menentukan outlier sesungguhnya



## INTEGRASI DATA (DATA INTEGRATION)



- Integrasi Data
  - ✓ satu langkah dalam data preprocessing yang terdiri atas proses penyatuan berbagai sumber menjadi satu dataset
  - ✓ Mengkombinasikan data dari banyak sumber simpanan ke dalam suatu terpadu
- Integrasi Skema
  - ✓ Mengintegrasikan metadata dari sumber-sumber berbeda
  - ✓ Problem identifikasi entitas: mengenali entitas dunia nyata dari banyak sumber-sumber data, misal A.cust-id  $\equiv$  B.cust-#
- Pendeteksian dan pemecahan konflik nilai data
  - ✓ Untuk entitas dunia nyata yang sama, nilai-nilai atribut dari sumber-sumber berbeda adalah berbeda
  - ✓ Alasan yang mungkin: representasi berbeda, skala berbeda, misal berat bisa dalam pound atau kilogram

## Integrasi Data



- Problem: integrasi skema heterogen
- Nama-nama atribut berbeda

| cid | name  | byear |
|-----|-------|-------|
| 1   | Jones | 1960  |
| 2   | Smith | 1974  |
| 3   | Smith | 1950  |

| Customer-ID | state |
|-------------|-------|
| 1           | NY    |
| 2           | CA    |
| 3           | NY    |

- Unit berbeda: Sales dalam \$, sales dalam Yen, sales dalam DM



## Integrasi Data



- Problem: integrasi skema heterogen
- Skala berbeda: Sales dalam dollar versus sales dalam sen dollar



- Atribut turunan: Annual salary versus monthly salary

| cid | monthlySalary |
|-----|---------------|
| 1   | 5000          |
| 2   | 2400          |
| 3   | 3000          |

| cid | Salary  |
|-----|---------|
| 6   | 50,000  |
| 7   | 100,000 |
| 8   | 40,000  |

## Integrasi Data

- Problem: ketidak-konsistenan karena redundansi
- Customer dengan customer-id 150 punya 3 anak dalam relation1 dan 4 anak dalam relation2

| cid | numChildren |
|-----|-------------|
| 1   | 3           |

| cid | numChildren |
|-----|-------------|
| 1   | 4           |

- Komputasi annual salary dari monthly salary dalam relation1 tak cocok dengan atribut “annual-salary” dalam relation2

| cid | monthlySalary |
|-----|---------------|
| 1   | 5000          |
| 2   | 6000          |

| cid | Salary |
|-----|--------|
| 1   | 60,000 |
| 2   | 80,000 |

## Penanganan Redundansi Dalam Integrasi Data

- Data redundan sering terjadi saat integrasi dari banyak database
  - Atribut yang sama bisa memiliki nama berbeda dalam database berbeda
  - Atribut yang satu bisa merupakan suatu atribut “turunan” dalam tabel lainnya, misal, annual revenue
- Data redundan mungkin bisa dideteksi dengan analisis korelasi
- Integrasi data hati-hati dari banyak sumber bisa membantu mengurangi/mencegah redundansi dan ketidak-konsistenan dan memperbaiki kecepatan dan kualitas mining

## Penanganan Redundansi Dalam Integrasi Data

- Suatu atribut adalah redundan jika atribut tersebut bisa diperoleh dari atribut lainnya
- Analisis korelasi  $r_{A,B} = \frac{\sum (A - \bar{A})(B - \bar{B})}{(n-1)\sigma_A\sigma_B}$
- Rata-rata A adalah  $\bar{A} = \frac{\sum A}{n}$
- Deviasi standard A adalah  $\sigma_A = \sqrt{\frac{\sum (A - \bar{A})^2}{n-1}}$
- $R_{A,B} = 0$ : A dan B saling bebas
- $R_{A,B} > 0$ : A dan B berkorelasi positif  $A \uparrow \leftrightarrow B \uparrow$
- $R_{A,B} < 0$ : A dan B berkorelasi negatif  $A \downarrow \leftrightarrow B \uparrow$



Beberapa pendekatan dalam data integration yang umum digunakan adalah

- **Data Consolidation** : pengumpulan, pemrosesan, dan penyimpanan data dalam satu lokasi seperti data warehouse
- **Data Virtualization** : penggunaan interface dashboard yang menyediakan real-time view terhadap data dari berbagai sumber berbeda

## TRANSFORMASI DATA (DATA TRANSFORMATION)

- 📌 Data transformation adalah salah satu langkah dalam data preprocessing untuk mengkonversi atau menyeragamkan data dari satu format ke format lain agar bisa dibaca oleh sistem komputasi.
- 📌 Contoh sederhananya seperti mengubah foto dokumen dalam format JPEG menjadi bentuk teks atau PDF
- 📌 Beberapa pendekatan yang umum digunakan untuk transformasi data :
  - ✓ **Smoothing** : menggunakan algoritma untuk menghapus/ menghilangkan noise data, sekaligus menemukan feature paling signifikan serta memprediksi pola dari dataset.
  - ✓ **Aggregation** : mengumpulkan data dari banyak sumber dan mengemasnya menjadi satu format yang dibutuhkan (ringkasan, konstruksi kubus data).

## TRANSFORMASI DATA (DATA TRANSFORMATION)

- 📌 Beberapa pendekatan yang umum digunakan untuk transformasi data :
  - ✓ **Discretization** : membagi continuous data menjadi beberapa interval untuk mengurangi ukurannya, misalnya membagi data rentang umur menjadi kategori anak-anak, remaja, dan dewasa
  - ✓ **Normalization** : mengkonversi variabel data guna mempersempit rentang data atau diskalakan agar jatuh didalam suatu range kecil yang tertentu, misalnya seperti mengubah data angka puluhan menjadi bilangan (0,1) saja.
  - ✓ **Generalization** : mengkonversi low-level data menjadi feature data yang high level, misalnya seperti mengubah atribut alamat lengkap menjadi atribut kota saja

## TRANSFORMASI DATA (DATA TRANSFORMATION)

- 📌 Beberapa pendekatan yang umum digunakan untuk transformasi data :
  - ✓ **Concept hierarchy Generation** : membentuk hierarki dari feature pada data guna mempermudah representasi data, misalnya mengubah data alamat lengkap menjadi beberapa feature yang terbagi atas nama jalan, nomor RT/RW, desa, dst.

## Transformasi Data: Normalisasi

- Normalisasi min-max

$$v' = \frac{v - \min_A}{\max_A - \min_A} (\text{new\_max}_A - \text{new\_min}_A) + \text{new\_min}_A$$

- Normalisasi z-score (saat Min, Max tak diketahui)

$$v' = \frac{v - \text{mean}_A}{\text{stand\_dev}_A}$$

- Normalisasi dengan penskalaan desimal

$$v' = \frac{v}{10^j} \quad \text{dimana } j \text{ adalah integer terkecil sehingga } \text{Max}(|v'|) < 1$$

## Transformasi Data: Normalisasi

- Normalisasi min-max

$$v' = \frac{v - \min_A}{\max_A - \min_A} (\text{new\_max}_A - \text{new\_min}_A) + \text{new\_min}_A$$

- Normalisasi z-score (saat Min, Max tak diketahui)

$$v' = \frac{v - \text{mean}_A}{\text{stand\_dev}_A}$$

- Normalisasi dengan penskalaan desimal

$$v' = \frac{v}{10^j} \quad \text{dimana } j \text{ adalah integer terkecil sehingga } \text{Max}(|v'|) < 1$$

## Agregasi

- **Agregasi (aggregation)** adalah proses mengkombinasikan dua atau lebih objek ke dalam sebuah objek tunggal. Agregasi data sangat berguna ketika pada set data ada sejumlah nilai dalam satu fitur yang sebenarnya satu kelompok, yang tidak akan menyimpang dari deskripsi fitur tersebut jika nilainya digabungkan.
- Agregasi yang dapat dilakukan adalah sum (jumlah), average (rata-rata), min (terkecil), max (terbesar).
- Sebagai contoh adalah data transaksi pembelian di beberapa cabang distributor. Setiap hari masing-masing cabang melakukan banyak sekali transaksi. Semua transaksi tersebut akan menghasilkan data yang besar dan kompleks. Oleh sebab itu data tersebut akan lebih sederhana tetapi tetap tidak menghilangkan deskripsinya apabila disajikan dalam bentuk gabungan setiap harinya di masing-masing cabang.
- Dengan begitu, pemrosesan data dalam data mining akan relatif lebih sederhana dan komputasinya menjadi lebih cepat. Selain itu dampaknya adalah penggunaan perangkat penyimpanan menjadi lebih sedikit atau kecil. Lebih jelasnya dapat dilihat pada tabel-tabel di bawah ini

## Agregasi

Set Data Transaksi Pembelian Oleh Pelanggan

| Cabang      | IDT    | Tanggal    | Total   |
|-------------|--------|------------|---------|
| Bandung     | B01001 | 30-01-2015 | 250.000 |
| Bandung     | B01002 | 30-01-2015 | 300.000 |
| Tasikmalaya | T01001 | 30-01-2015 | 500.000 |
| Tasikmalaya | T01002 | 30-01-2015 | 450.000 |
| Tasikmalaya | T01003 | 31-01-2015 | 350.000 |

Misalnya kita menggunakan agregasi sum pada kolom total, dikelompokkan berdasarkan kolom tanggal dan kolom IDT dapat dihilangkan sehingga hasilnya tampak seperti pada tabel 2 di bawah ini.


Set Data Transaksi Pembelian Oleh Pelanggan Setelah Agregasi

| Cabang      | Tanggal    | Total   |
|-------------|------------|---------|
| Bandung     | 30-01-2015 | 550.000 |
| Tasikmalaya | 30-01-2015 | 950.000 |
| Tasikmalaya | 31-01-2015 | 350.000 |

## Agregasi Kubus Data

- Level terendah dari suatu kubus data
  - Data agregasi data untuk suatu **individu entitas yang diminati**
  - Misal, suatu customer dalam suatu DW phone calling.
- Banyak level agregasi dalam kubus data
  - Pengurangan ukuran data yang diurusi berikutnya
- Rujukan level yang sesuai
  - Menggunakan representasi terkecil yang cukup untuk memecahkan tugasnya
- Query yang berkaitan dengan agregasi informasi harus dijawab menggunakan kubus data, bila mungkin

## Agregasi Kubus Data



## REDUKSI DATA (DATA REDUCTION)


- Data reduction adalah proses pengurangan volume atau kuantitas data dengan hanya menyimpan data yang penting saja.
- Tujuan dari reduksi data adalah untuk meningkatkan efisiensi analisis data dan menghindari overfitting.
- Terdapat beberapa teknik yang umum digunakan untuk reduksi data :
  - ✓ **Dimensionality reduction** : pengurangan variabel atau atribut dengan cara menyatukan data dengan karakteristik yang serupa atau berkorelasi dengan satu sama lain
  - ✓ **Numerosity reduction** : penggantian data asli dengan representasi data yang lebih kecil atau lebih sempit, representasi data dapat ditentukan dengan model regresi atau clustering.
  - ✓ **Data Compression** : mengemas data dengan cara melakukan kompresi agar ukurannya jadi lebih kecil untuk tujuan penyimpanan atau data transmission.

## Reduksi Dimensionalitas

- Fitur seleksi (i.e., attribute subset selection):
  - Memilih sekumpulan fitur minimum sedemikian hingga distribusi peluang dari kelas berbeda bila nilai-nilai fitur tersebut diberikan adalah sedekat mungkin dengan distribusi asli bila nilai-nilai diberikan pada seluruh fitur
  - Mengurangi jumlah pola dalam pola, lebih mudah dipahami
- Metoda heuristik (due to exponential # of choices):
  - Seleksi step-wise forward
  - Eliminasi step-wise backward
  - Kombinasi seleksi forward dan eliminasi backward
  - Induksi pohon keputusan

## Contoh Induksi Pohon Keputusan

Himpunan atribut awal:  
 $\{A1, A2, A3, A4, A5, A6\}$



.....> Reduksi himpunan atribut:  $\{A1, A4, A6\}$


## Fitur Seleksi Metoda Heuristik

- Ada sebanyak  $2^d$  sub-fitur yang mungkin dari  $d$  fitur
- Beberapa fitur seleksi metoda heuristik:
  - Fitur tunggal terbaik dibawah asumsi fitur bebas: pilih dengan uji berarti.
  - Fitur seleksi step-wise terbaik:
    - Fitur tunggal terbaik dipilih pertama kali
    - Lalu kondisi fitur terbaik untuk yang pertama...
  - Fitur eliminasi step-wise:
    - Secara berulang-ulang menghilangkan fitur yang buruk
  - Kombinasi fitur seleksi dan eliminasi terbaik:
  - Branch and bound optimal:
    - Menggunakan fitur eliminasi dan backtracking

## Kompresi Data

- Kompresi string
  - Ada banyak teori dan algoritma yang telah diselaraskan dengan baik
  - Biasanya lossless
  - Tetapi hanya manipulasi terbatas yang mungkin tanpa perluasan
- Kompresi audio/video
  - Biasanya kompresi lossy, dengan penghalusan progresif
  - Kadang-kadang fragmen kecil dari sinyal bisa direkonstruksi tanpa rekronstruksi keseluruhan
- Urutan waktu bukanlah video
  - Biasanya pendek dan bervariasi lambat menurut waktu


## Kompresi Data





## Transformasi Wavelet



- Discrete wavelet transform (DWT): pemrosesan sinyal linier, analisis multiresolusional
- Pendekatan terkompres: menyimpan hanya suatu bagian kecil dari yang terkuat dari koefisien wavelet
- Mirip dengan Discrete Fourier transform (DFT), tetapi kompresi lossy yang lebih baik, dilokalisasi dalam ruang



## Transformasi Wavelet

- Metoda:
  - Panjang,  $L$ , haruslah suatu integer pangkat 2 (diisi dengan 0, bila diperlukan)
  - Setiap transformasi memiliki 2 fungsi: penghalusan dan beda
  - Diterapkan pada pasangan data, yang menghasilkan 2 set data dari panjang  $L/2$
  - Memakai 2 fungsi secara rekursif, sampai panjang yang diinginkan tercapai


## DWT Untuk Kompresi Citra



## Analisis Komponen Utama

- Diberikan  $N$  vektor data dari  $k$ -dimensi, cari vektor-vektor ortogonal  $c \leq k$  yang paling baik digunakan untuk menyajikan data
  - Himpunan data asli dikurangi menjadi himpunan yang memuat  $N$  vektor-vektor data pada komponen utama  $c$  (mengurangi dimensi)
- Setiap vektor data adalah suatu kombinasi linier dari vektor-vektor komponen utama  $c$
- Berlaku hanya untuk data numerik
- Digunakan ketika jumlah dimensi besar

## Analisis Komponen Utama



## Reduksi Numerositi

- Metoda parametrik
  - Misalkan data sesuai dengan suatu model, taksir parameter-parameter model, simpan hanya parameter-parameter tersebut, dan buang datanya (kecuali outlier yang mungkin)
  - Model-model log-linear: dapatkan nilai-nilai pada suatu titik dalam ruang  $m$ -D sebagai perkalian atas ruang bagian marginal yang sesuai
- Metoda non-parametrik
  - Tidak memandang model
  - Keluarga utama: histogram, clustering, sampling

## Model Regresi dan Log-linier

- Regresi linier: Data dimodelkan agar masuk kedalam suatu garis lurus
  - Sering menggunakan metoda least-square agar memenuhi garis tersebut
- Regresi ganda: memungkinkan suatu variabel respon Y untuk dimodelkan sebagai suatu fungsi linier dari vektor fitur multidimensional
- Model log-linear: mendekati distribusi peluang multidimensional diskrit

## Analisa Regresi dan Model log-linier

- Regresi linear:  $Y = \alpha + \beta X$ 
  - 2 parameter,  $\alpha$  dan  $\beta$  yang menentukan garis tersebut dan akan ditaksir menggunakan data yang dimiliki.
  - Menggunakan kriteria least squares untuk nilai-nilai yang diketahui dari  $Y_1, Y_2, \dots, X_1, X_2, \dots$
- Regresi ganda:  $Y = b_0 + b_1 X_1 + b_2 X_2$ .
  - Berbagai fungsi nonlinier bisa ditransformasikan ke regresi linier.
- Model log-linear:
  - Tabel multi-way dari peluang gabungan didekati dengan suatu perkalian dari tabel-tabel orde lebih rendah.
  - Peluang:  $p(a, b, c, d) = \alpha_{ab} \beta_{ac} \gamma_{ad} \delta_{bcd}$

## Histogram

- Teknik reduksi data populer
- Membagi data kedalam ember-ember dan menyimpan rata-rata (jumlah) untuk setiap ember
- Bisa dibangun secara optimal dalam satu dimensi menggunakan pemrograman dinamis
- Terkait dengan problem kuantisasi

## Histogram

- Contoh:  
Dataset: 1,1,1,1,1,1,1,2,2,2,2,3,3,4,4,5,5,6,6,7,7,8,8,9,9,10,10,11,11,12,12  
Histogram: (range, count, sum)  
(1-2,12,16), (3-6,8,36), (7-9,6,48), (10-12,6,66)
- Histogram lebar sama
  - Membagi domain dari suatu atribut kedalam k interval dengan ukuran sama
  - Lebar interval =  $(\text{Max} - \text{Min})/k$
  - Secara komputasi mudah
  - Problem dengan skew data dan outliers

## Histogram

- Contoh:  
Dataset: 1,1,1,1,1,1,1,2,2,2,2,3,3,4,4,5,5,6,6,  
7,7,8,8,9,9,10,10,11,11,12,12  
Histogram: (range, count, sum)  
(1-3,14,22), (4-6,6,30), (7-9,6,48), (10-12,6,66)
- Histogram kedalaman sama
  - Membagi domain dari suatu atribut kedalam k interval, masing-masing interval memuat jumlah record yang sama
  - Variabel lebar interval
  - Komputasinya mudah

## Histogram

- Contoh:  
Dataset: 1,1,1,1,1,1,1,2,2,2,2,3,3,4,4,5,5,6,6,  
7,7,8,8,9,9,10,10,11,11,12,12  
Histogram: (range, count, sum)  
(1,8,8), (2-4,8,22), (5-8,8,52), (9-12,8,84)


## Clustering

- Mempartisi data set kedalam cluster-cluster, dan bisa hanya menyimpan representasi cluster
- Bisa sangat efektif jika data di-cluster tetapi tidak jika data “dirusak”
- Bisa memiliki clustering hierarki dan bisa disimpan didalam struktur pohon indeks multi-dimensional
- Ada banyak pilihan dari definisi clustering dan algoritma clustering.


## Sampling

- Memungkinkan suatu algoritma mining untuk dijalankan dalam kompleksitas yang berpotensi sub-linier terhadap ukuran data
- Pilih suatu **perwakilan** subset dari data tersebut
  - Sampling acak sederhana bisa memiliki kinerja yang sangat buruk bila ada skew
- Kembangkan metoda-metoda sampling adaptif
  - Stratifikasi sampling:
    - Dekati persentasi dari masing-masing kelas (atau subpopulasi yang diminati) dalam database keseluruhan
    - Digunakan dalam hubungannya dengan skewed data
- Sampling bisa tidak mengurangi I/O database (halaman pada suatu waktu).

## Sampling



## Sampling





## Reduksi Hierarki


- Gunakan struktur multi resolusi dengan derajat reduksi berbeda
- Clustering hierarkikal sering dilakukan tetapi cenderung mendefinisikan partisi data sets ketimbang “cluster”
- Metoda paramaterik biasanya tidak dapat diuji untuk representasi hierarkikal
- Agregasi hierarkikal
  - Suatu pohon indeks hierarkikal membagi suatu data set kedalam partisi-partisi dengan memberi nilai range dari beberapa atribut
  - Setiap partisi bisa dipandang sebagai suatu ember
  - Jadi suatu pohon indeks dengan agregasi yang disimpan pada setiap node adalah suatu histogram hierarkikal

## Diskritisasi

- Konsep sama dengan histogram
- Membagi domain dari suatu atribut numerik kedalam interval-interval.
- Menggantikan nilai atribut dengan label untuk interval.
- Contoh:
  - Dataset (age; salary):  
(25;30,000),(30;80,000),(27;50,000),  
(60;70,000),(50;55,000),(28;25,000)
  - Dataset diskrit(age, discretizedSalary):  
(25,low),(30,high),(27,medium),(60,high),  
(50,medium),(28,low)

## Diskritisasi

- 3 tipe dari atribut:
  - Nominal — nilai-nilai dari sekumpulan tak berurut
  - Ordinal — nilai-nilai dari suatu himpunan terurut
  - Continuous — bilangan-bilangan riil
- Diskritisasi:
  - Membagi range dari suatu atribut kontinu kedalam interval-interval



- Beberapa algoritma klasifikasi hanya menerima atribut kategorikal.
- Mengurangi ukuran data dengan diskritisasi
- Menyiapkan data untuk analisis lebih lanjut

## Diskritisasi dan Konsep Hierarki

- Diskritisasi
  - Mengurangi jumlah nilai-nilai dari atribut kontinu yang diberikan dengan membagi range atribut kedalam interval-interval. Label-label interval kemudian bisa digunakan untuk menggantikan nilai-nilai data sesungguhnya
- Konsep hierarki
  - Mengurangi data melalui pengumpulan dan penggantian konsep level rendah (seperti nilai-nilai numerik untuk numerik usia) dengan konsep level lebih tinggi (seperti muda, middle-aged, atau senior)

## Diskritisasi dan Konsep Hierarki Pembuatan Data Numerik

- Binning
- Analisis Histogram
- Analisis Clustering
- Diskritisasi berbasis entropy
- Segmentasi dengan partisi alami


## Diskritisasi Berbasis Entropi

- Diberikan suatu himpunan sampel  $S$ , jika  $S$  dipartisi kedalam 2 interval  $S_1$  dan  $S_2$  menggunakan batas  $T$ , entropi setelah partisi adalah 
$$E(S, T) = \frac{|S_1|}{|S|} Ent(S_1) + \frac{|S_2|}{|S|} Ent(S_2)$$
- Batas yang meminimisasi fungsi entropi atas seluruh batas-batas yang mungkin dipilih sebagai suatu diskritisasi biner.
- Proses ini secara rekursif diterapkan pada partisi yang diperoleh sampai suatu kriteria penghentian ditemukan, misal,  $Ent(S) - E(T, S) > \delta$
- Percobaan-percobaan menunjukkan bahwa bahwa diskritisasi ini bisa mengurangi ukuran data dan memperbaiki akurasi klasifikasi

## Segmentasi Dengan Partisi Alami

- Suatu kaidah 3-4-5 sederhana bisa digunakan untuk memecah data numerik kedalam interval “alami” yang relatif seragam.
  - Jika suatu interval memuat 3, 6, 7 atau 9 nilai-nilai berbeda pada digit paling berarti, partisi range tersebut menjadi 3 interval dengan lebar sama
  - Jika suatu interval memuat 2, 4, atau 8 nilai-nilai berbeda pada digit paling berarti, partisi range tersebut kedalam 4 interval
  - Jika suatu interval memuat 1, 5, atau 10 nilai-nilai berbeda pada digit paling berarti, partisi range kedalam 5 interval

## Contoh Kaidah 3-4-5



## Pembuatan Konsep Hierarki Untuk Data Kategorikal

- Spesifikasi dari suatu urutan parsial dari atribut secara eksplisit pada level skema oleh user atau pakar
  - street<city<state<country
- Spesifikasi dari suatu bagian dari suatu hierarki dengan pengelompokan data secara eksplisit
  - {Urbana, Champaign, Chicago}<Illinois
- Spesifikasi dari suatu himpunan atribut.
  - Sistem secara otomatis membangun urutan parsial dengan menganalisa jumlah nilai-nilai berbeda
  - Misal, street < city <state < country
- Spesifikasi dari hanya suatu himpunan parsial dari atribut
  - misal, hanya street < city, bukan lainnya

## Pembuatan Konsep Hierarki Otomatis

- Beberapa konsep hierarki bisa secara otomatis dibangun berdasarkan pada analisis dari jumlah nilai-nilai berbeda per atribut dalam data set yang diberikan
  - Atribut dengan nilai-nilai paling berbeda diletakkan pada level terbawah dari hierarki
  - Catatan: Pengecualian—weekday, month, quarter, year

## Pembuatan Konsep Hierarki Otomatis

