



ALGORITMA C4.5

- Algoritma C4.5 diperkenalkan oleh Quinlan (1996) sebagai versi perbaikan dari ID3. Dalam ID3, induksi decision tree hanya bisa dilakukan pada fitur bertipe kategorikal (nominal atau ordinal), sedangkan tipe numerik tidak dapat digunakan.
- Yang membedakan algoritma C4.5 dari ID3 adalah dapat menangani fitur dengan tipe numerik, melakukan pemotongan (prunning) decision tree, dan penurunan (deriving) rule set.
- Algoritma C4.5 juga menggunakan kriteria gain dalam menentukan fitur yang menjadi pemecah node pada pohon yang diinduksi

KELEBIHAN ALGORITMA C4.5

1. Mampu menganani atribut dengan tipe data diskrit dan KOntinyu

PASIEEN	USIA	HASIL
1	21	YA
2	17	YA
3	25	TIDAK
4	30	TIDAK
5	45	YA
6	61	TIDAK
7	35	YA
8	50	YA
9	75	TIDAK
10	31	TIDAK



USIA $\leq$ 35 : YA/3, TIDAK/2
USIA $>$ 35 : YA/2, TIDAK/3

3

KELEBIHAN ALGORITMA C4.5

2. Mampu menganani atribut kosong

PASIEEN	USIA	HASIL
1	?	YA
2	17	YA
3	33	TIDAK
4	30	TIDAK
5	25	YA
6	50	TIDAK
7	25	YA
8	50	YA
9	40	TIDAK
10	31	TIDAK



PASIEEN	USIA	HASIL
1	25	YA
2	17	YA
3	33	TIDAK
4	30	TIDAK
5	25	YA
6	50	TIDAK
7	25	YA
8	50	YA
9	40	TIDAK
10	31	TIDAK

Diisi dengan data 25 karena data tersebut mayoritas . Selain data numerik juga bisa diisikan utk data kategorikal. Namun sebenarnya lebih baik jika sebelum proses mining, dilakukan proses cleaning aja

4

KELEBIHAN ALGORITMA C4.5

3. Pemangkasan pohon keputusan

PrePruning

- ✓ Menghentikan pembangunan suatu subtree lebih awal yaitu dengan memutuskan untuk tidak lebih jauh mempartisi data training jika partisi yang akan dibuat dianggap tidak signifikan
- ✓ Misal interval node memiliki kelas ya =5 dan tidak =1
- ✓ Data pada kelas **tidak** merupakan **noise**, sehingga apabila data tersebut diolah akan menghasilkan pohon dengan subtree yang panjang

5

KELEBIHAN ALGORITMA C4.5

3. Pemangkasan pohon keputusan

PostPruning

- ✓ Menyederhanakan pohon dengan cara membuang beberapa cabang subtree setelah pohon selesai dibangun

6

ALGORITMA C4.5

Tahapan dalam algoritma C4.5 adalah

1. Pilih atribut sebagai akar
2. Buat cabang untuk masing2 nilai
3. Bagi kasus dalam cabang
4. Ulangi proses untuk masing2 cabang sampai semua kasus pada cabang memiliki kelas yang sama

7

ALGORITMA C4.5

TAHAPAN ALGORITMA C4.5

1. Persiapan data
2. Hitung nilai entropy
3. Setelah mendapatkan nilai dari entropy, maka akan digunakan untuk mencari nilai gain
4. Kemudian menentukan nilai Split info
5. Setelah mendapatkan nilai Gain dan Split info, kemudian menentukan nilai Gain Ratio.
6. Nilai Gain Ration tertinggi akan digunakan sebagai akar. Sehingga terbentuklah pohon keputusan sebagai node 1

8

ALGORITMA C4.5

TAHAPAN ALGORITMA C4.5

7. Ulangi proses ke-2 sampai semua cabang memiliki kelas yang sama
8. Dari pohon keputusan yang terbentuk maka dapat ditentukan Rule-rule

9

ALGORITMA C4.5

ENTROPY

$$Entropy(S) = \sum_{i=1}^n - p_i \cdot \log_2 p_i$$

✓ Keterangan :

S = himpunan (dataset) kasus

n = jumlah (banyaknya) partisi S atau jumlah nilai berbeda pada atribut target (jumlah/banyak kelas)

p_i = porsi atau rasio antara jumlah sampel di kelas i dg jumlah sampel pada himpunan data atau proporsi dari S_i terhadap S atau probabilitas yg didapat dari $\sum (Y_i)$ dibagi total kasus.

10

ALGORITMA C4.5

GAIN

Ukuran efektifitas (keuntungan) suatu atribut dalam mengklasifikasikan data

$$Gain(S, A) = Entropy(S) - \sum_{i=1}^c \frac{|S_i|}{|S|} * Entropy(S_i)$$

✓ Keterangan :

S = himpunan (dataset) kasus

A = Atribut

c = jumlah (banyaknya) partisi atribut A

|S_i| = jumlah kasus/sampel pada partisi ke-l

|S| = jumlah kasus/sampel dalam S

11

ALGORITMA C4.5

SPLIT INFO

Split Info menyatakan entropy atau informasi potensial

$$SplitInfo(S, A) = - \sum_{i=1}^c \frac{S_i}{S} \log \frac{S_i}{S}$$

✓ Keterangan :

S = himpunan (dataset) kasus

A = Atribut

S_i = jumlah kasus/sampel untuk atribut A

12

ALGORITMA C4.5

GAIN RATIO

Untuk memilih atribut sebagai akar, didasarkan pada nilai gain ratio tertinggi dari atribut-atribut yang ada

$$\text{GainRatio}(S, A) = \frac{\text{Gain}(S, A)}{\text{SplitInfo}(S, A)}$$

✓ Keterangan :

S = himpunan (dataset) kasus

A = Atribut

Gain(S,A) = Information Gain pada Atribut A

SplitInfo(S,A) = Split information pada Atribut A

13

CONTOH ALGORITMA C4.5

Berikut contoh penerapan algoritma C4.5 untuk menentukan keputusan bermain playball atau tidak.

Langkah 1:

NO	OUTLOOK	TEMPERATURE	HUMIDITY	WINDY	PLAY
1	SUNNY	85	85	FALSE	NO
2	SUNNY	80	90	TRUE	NO
3	CLOUDY	83	78	FALSE	YES
4	RAINY	70	96	FALSE	YES
5	RAINY	68	80	FALSE	YES
6	RAINY	65	70	TRUE	YES
7	CLOUDY	64	65	TRUE	YES
8	SUNNY	72	95	FALSE	NO
9	SUNNY	69	70	FALSE	YES
10	RAINY	75	80	FALSE	YES
11	SUNNY	75	70	TRUE	YES
12	CLOUDY	72	90	TRUE	YES
13	CLOUDY	81	75	FALSE	YES
14	RAINY	71	80	TRUE	NO

14

Langkah 2: PERHITUNGAN NODE 1 (ROOT/ENTROPY)

Diketahui :

- Jumlah Kasus (S) = 14
- Jumlah Kasus - NO (S1) = 4
- Jumlah Kasus - YES (S2) = 10
- Entropy Total (S) =

$$\begin{aligned} Entropy(Total) &= \left(-\frac{1}{14} * 2 \log \frac{4}{14} \right) + \left(-\frac{10}{14} * 2 \log \frac{10}{14} \right) \\ &= 0,863120569 \end{aligned}$$

15

Langkah 2: HITUNG NILAI ENTROPY ATRIBUT OUTLOOK (CLOUDY)

Diketahui :

- Jumlah Kasus Cloudy = 4
- Jumlah Kasus Cloudy - NO = 0
- Jumlah Kasus Cloudy - YES = 4
- Hitung Entropy Cloudy =

$$\begin{aligned} Entropy(CLOUDY) &= \left(-\frac{0}{4} * \log_2 \left(\frac{0}{4} \right) \right) + \left(-\frac{4}{4} * \log_2 \left(\frac{4}{4} \right) \right) \\ Entropy(CLOUDY) &= 0 \end{aligned}$$

16

Langkah 2: HITUNG NILAI ENTROPY ATRIBUT OUTLOOK (RAINY)

Diketahui :

- Jumlah Kasus Rainy = 5
- Jumlah Kasus Rainy - NO = 1
- Jumlah Kasus Rainy - YES = 4
- Hitung Entropy Rainy =

$$\begin{aligned} Entropy(Rainy) &= \left(-\frac{1}{5} \cdot \log \frac{1}{5} \right) + \left(-\frac{4}{5} \cdot \log \frac{4}{5} \right) \\ &= 0,721928095 \end{aligned}$$

17

Langkah 2: HITUNG NILAI ENTROPY ATRIBUT OUTLOOK (SUNNY)

Diketahui :

- Jumlah Kasus Sunny = 5
- Jumlah Kasus Sunny - NO = 3
- Jumlah Kasus Sunny - YES = 2
- Hitung Entropy Sunny =

$$\begin{aligned} Entropy(Sunny) &= \left(-\frac{3}{5} \cdot \log \frac{3}{5} \right) + \left(-\frac{2}{5} \cdot \log \frac{2}{5} \right) \\ &= 0,970950594 \end{aligned}$$

18

Langkah 3 : PERHITUNGAN GAIN ATRIBUT OUTLOOK

$$Gain(Total, Outlook) = Entropy(Total) - \sum_1^n \frac{|Outlook|}{Total} * Entropy(Outlook)$$

$$Gain(Total, Outlook) = 0,863120569 - \left(\left(\frac{4}{14} * 0 \right) + \left(\frac{5}{14} * 0,72193 \right) + \left(\frac{5}{14} * 0,97095 \right) \right)$$

$$Gain(Total, Outlook) = 0,258521037$$

19

Langkah 4 : PERHITUNGAN SPLIT INFO OUTLOOK

Diketahui :

- Jumlah Kasus Cloudy = 4
- Jumlah Kasus Rainy = 5
- Jumlah Kasus Sunny = 5
- Hitung Split Info =

$$SplitInfo(Total, Outlook) = \left(-\frac{4}{14} * 2 \log \frac{4}{14} \right) + \left(-\frac{5}{14} * 2 \log \frac{5}{14} \right) + \left(-\frac{5}{14} * 2 \log \frac{5}{14} \right)$$

$$= 1,577406283$$

20

Langkah 5: PERHITUNGAN GAIN RATIO OUTLOOK

$$\text{GainRatio}(\text{Total}, \text{Outlook}) = \frac{\text{Gain}(\text{Total}, \text{Outlook})}{\text{SplitInfo}(\text{Total}, \text{Outlook})}$$

$$\text{GainRatio}(\text{Total}, \text{Outlook}) = \frac{0,258521037}{1,577406283} = 0,16388995$$

21

ULANGI PERHITUNGAN PADA DATA DISKRIT ATAU KONTINYU

Dengan cara yang sama, lakukan perhitungan pada atribut diskrit dengan membuat split pada nilai tersebut.

Misal :

Hitung pada Atribut Humidity

Urutkan nilai dari terkecil - terbesar
(Ascending)

NO	HUMIDITY	PLAY
7	65	Yes
6	70	Yes
9	70	Yes
11	70	Yes
13	75	Yes
3	78	Yes
5	80	Yes
10	80	Yes
14	80	No
1	85	No
2	90	No
12	90	Yes
8	95	No
4	96	Yes

22

HITUNG ENTROPY HUMIDITY <= 65

Diketahui :

- Jumlah Kasus Humidity <= 65 : 1
- Jumlah Kasus Humidity <= 65 - NO : 0
- Jumlah Kasus Humidity <= 65 – YES : 1

$$Entropy(Humidity \leq 65) = \left(-\frac{0}{1} * \log \frac{0}{1} \right) + \left(-\frac{1}{1} * \log \frac{1}{1} \right) = 0$$

NO	HUMIDITY	PLAY
7	65	Yes
6	70	Yes
9	70	Yes
11	70	Yes
13	75	Yes
3	78	Yes
5	80	Yes
10	80	Yes
14	80	No
1	85	No
2	90	No
12	90	Yes
8	95	No
4	96	Yes

23

HITUNG ENTROPY HUMIDITY > 65

Diketahui :

- Jumlah Kasus Humidity > 65 : 13
- Jumlah Kasus Humidity > 65 - NO : 4
- Jumlah Kasus Humidity > 65 – YES : 9

$$Entropy(Humidity > 65) = \left(-\frac{4}{13} * \log \frac{4}{13} \right) + \left(-\frac{9}{13} * \log \frac{9}{13} \right) = 0,89049164$$

NO	HUMIDITY	PLAY
7	65	Yes
6	70	Yes
9	70	Yes
11	70	Yes
13	75	Yes
3	78	Yes
5	80	Yes
10	80	Yes
14	80	No
1	85	No
2	90	No
12	90	Yes
8	95	No
4	96	Yes

24

HITUNG GAIN HUMIDITY <> 65

$$Gain(Total, HUMIDITY <> 65) = Entropy(Total) - \sum_{i=1}^n \frac{|Humidity <> 65_i|}{|Total|} * Entropy(Humidity <> 65_i)$$

$$Gain(Total, Humidity <> 65) = 0,863120569 - ((\frac{1}{14} * 0) + (\frac{13}{14} * 0,89049164))$$

$$Gain(Total, Humidity <> 65) = 0,036235474$$

25

HITUNG SPLIT INFO HUMIDITY <> 65

Diketahui :

- Jumlah Kasus Total adalah 14
- Jumlah Kasus <= 65 adalah 1
- Jumlah Kasus > 65 adalah 13
- Hitung Split Info

$$SplitInfo(Total, Humidity \diamond 65) = \left(-\frac{1}{14} * 2 \log \frac{1}{14} \right) + \left(-\frac{13}{14} * 2 \log \frac{13}{14} \right) \\ = 0,371232327$$

26

HITUNG GAIN RATIO HUMIDITY <> 65

$$\text{GainRatio}(\text{Total}, \text{Humidity} \neq 65) = \frac{\text{Gain}(\text{Total}, \text{Humidity} \neq 65)}{\text{SplitInfo}(\text{Total}, \text{Humidity} \neq 65)}$$

$$\text{GainRatio}(\text{Total}, \text{Humidity} \neq 65) = \frac{0,036235474}{0,371232327} = 0,097608617$$

27

ULANGI PROSES UNTUK SETIAP AMBANG BATAS PADA HUMIDITY

NO	HUMIDITY	PLAY
7	65	Yes
6	70	Yes
9	70	Yes
11	70	Yes
13	75	Yes
3	78	Yes
5	80	Yes
10	80	Yes
14	80	No
1	85	No
2	90	No
12	90	Yes
8	95	No
4	96	Yes

28

HASIL PERHITUNGAN HUMIDITY < > 65

HUMIDITY	JML KASUS	NO (S1)	YES (S2)	ENTROPY	GAIN	SPLIT INFO	GAIN RATIO
					0,036235474	0,371232327	0,097608617
<=65	1	0	1	0			
>65	13	4	9	0,89049164	0,16958443	0,863120569	0,196478263
<=70	4	0	4	0			
>70	10	4	6	0,970950594	0,226000244	0,940285959	0,240352674
<=75	5	0	5	0			
>75	9	4	5	0,99107606	0,291691997	0,985228136	0,296065435
<=78	6	0	6	0			
>78	8	4	4	1	0,192829284	0,940285959	0,20507515
<=80	9	1	8	0,503258335			
>80	5	3	2	0,970950594	0,061743358	0,863120569	0,071535033
<=85	10	2	8	0,721928095			
>85	4	2	2	1	0,024882176	0,591672779	0,042053948
<=90	12	3	9	0,811278124			
>90	2	1	1	1	0,036235474	0,371232327	0,097608617
<=95	13	4	9	0,89049164			
>95	1	0	1	0			

29

HITUNG NILAI SELURUH ATRIBUT

ULANGI PROSES PERHITUNGAN ENTROPY, GAIN, SPLIT INFO, DAN GAIN RATIO UNTUK ATRIBUT YANG LAIN, YAITU TEMPERATURE, DAN WINDY

MASUKKAN SELURUH HASIL PERHITUNGAN KE DALAM TABEL

30

HASIL PERHITUNGAN UNTUK ROOT NODE

NODE	ATRIBUT	VALUE	JML KASUS (S)	NO (S_1)	YES (S_2)	ENTROPY	GAIN	SPLIT INFO	GAIN RATIO
1	TOTAL		14	4	10	0.863120569			
	OUTLOOK						0.258521037	1,577406283	0,16388995
		CLOUDY	4	0	4	0			
		RAINY	5	1	4	0.721928095			
		SUNNY	5	3	2	0.970950594			
	TEMPERATURE						0,226000244	0,940285959	0,240352674
		<=70	5	0	5	0			
		>70	9	4	5	0,99107606			
	HUMIDITY						0,291691997	0,985228136	0,296065435
		<=78	6	0	6	0			
		>78	8	4	4	1			
	WINDY						0.005977711	0,985228136	0,006067337
		FALSE	8	2	6	0.811278124			
		TRUE	6	2	4	0.918295834			

CARI NODE BERIKUTNYA

DENGAN CARA YANG SAMA SEPerti PADA PERHITUNGAN NODE 1, CARi NODE BERIKUTNYA DENGAN MEMFILTER DATA BERDASARKAN NILAI ATRIBUT HUMIDITY > 78

NO	OUTLOOK	TEMPERATURE	HUMIDITY	WINDY	PLAY
1	SUNNY	85	85	FALSE	No
2	SUNNY	80	90	TRUE	No
4	RAINY	70	96	FALSE	Yes
5	RAINY	68	80	FALSE	Yes
8	SUNNY	72	95	FALSE	No
10	RAINY	75	80	FALSE	Yes
12	CLOUDY	72	90	TRUE	Yes
14	RAINY	71	80	TRUE	No

HASIL PERHITUNGAN NODE BERIKUTNYA

HASIL PERHITUNGAN ENTROPY, GAIN, DAN GAIN RATIO UNTUK HUMIDITY > 78


NODE	ATRIBUT	VALUE	JML KASUS (S)	NO (S_1)	YES (S_2)	ENTROPY	GAIN	SPLIT INFO	GAIN RATIO
1.1	HUMIDITY >78		8	4	4	1			
	OUTLOOK						0,594360938	1,405639062	0,422840368
		CLOUDY	1	0	1	0			
		RAINY	4	1	3	0,811278124			
		SUNNY	3	3	0	0			
	TEMPERATURE						0,311278124	0,811278124	0,383688547
		<=70	2	0	2	0			
		>70	6	4	2	0,918295834			
	WINDY						0,048794941	0,954434003	0,051124479
		FALSE	5	2	3	0,970950594			
		TRUE	3	2	1	0,918295834			

33

CABANG 1.1 = OUTLOOK

NILAI GAIN RATIO TERTINGGI UNTUK HUMIDITY > 78 ADALAH ATRIBUT
OUTLOOK = 0,383688547

ATRIBUT	VALUE	JML KASUS (S)	NO (S_1)	YES (S_2)
OUTLOOK				
	CLOUDY	1	0	1
	RAINY	4	1	3
	SUNNY	3	3	0



34

HUMIDITY > 78 AND OUTLOOK = RAINY

NO	OUTLOOK	TEMPERATURE	HUMIDITY	WINDY	PLAY
4	RAINY	70	96	FALSE	Yes
5	RAINY	68	80	FALSE	Yes
10	RAINY	75	80	FALSE	Yes
14	RAINY	71	80	TRUE	No

35

CABANG 1.1.2 : WINDY

NILAI GAIN RATIO TERTINGGI UNTUK
HUMIDITY > 78 AND OUTLOOK = RAINY
ADALAH ATRIBUT **WINDY** = 1

ATRIBUT	VALUE	JML KASUS (S)	NO (S ₁)	YES (S ₂)
WINDY	FALSE	3	0	3
	TRUE	1	1	0



LATIHAN SOAL ALGORITMA C4.5

DIKETAHUI TABEL TENTANG “BUYS COMPUTER”, BUATLAH
DECISION TREE MENGGUNAKAN 1D3 DAN C4.5.

age	income	student	credit_rating
<=30	high	no	fair
<=30	high	no	excellent
31...40	high	no	fair
>40	medium	no	fair
>40	low	yes	fair
>40	low	yes	excellent
31...40	low	yes	excellent
<=30	medium	no	fair
<=30	low	yes	fair
>40	medium	yes	fair
<=30	medium	yes	excellent
31...40	medium	no	excellent
31...40	high	yes	fair
>40	medium	no	excellent

37

38