

Naïve Bayes Classifier

By. Auli Damayanti



INTRODUCTION

- ✓ **Naïve Bayes** merupakan sebuah pengklasifikasian probabilistik sederhana yang menghitung sekumpulan probabilitas dengan menjumlahkan frekuensi dan kombinasi nilai dari dataset yang diberikan.
- ✓ **Algoritma Naïve Bayes** merupakan sebuah metoda klasifikasi menggunakan metode probabilitas dan statistik yg dikemukakan oleh ilmuwan Inggris Thomas Bayes.
- ✓ **Algoritma Naïve Bayes** memprediksi peluang di masa depan berdasarkan pengalaman di masa sebelumnya sehingga dikenal sebagai Teorema Bayes.
- ✓ Ciri utama dr Naïve Bayes Classifier ini adalah asumsi yg sangat kuat (naïf) akan independensi dari masing-masing kondisi / kejadian.



INTRODUCTION

- ✓ Naive Bayes Classifier bekerja sangat baik dibanding dengan model classifier lainnya.
- ✓ Hal ini dibuktikan pada jurnal *Xhemali, Daniela, Chris J. Hinde, and Roger G. Stone. "Naïve Bayes vs. decision trees vs. neural networks in the classification of training web pages." (2009)*, mengatakan bahwa "Naïve Bayes Classifier memiliki tingkat akurasi yg lebih baik dibanding model classifier lainnya".
- ✓ Keuntungan penggunaan adalah bahwa metoda ini hanya membutuhkan jumlah data pelatihan (training data) yang kecil untuk menentukan estimasi parameter yg diperlukan dalam proses pengklasifikasian.
- ✓ Karena yg diasumsikan sebagai variabel independent, maka hanya varians dari suatu variabel dalam sebuah kelas yang dibutuhkan untuk menentukan klasifikasi, bukan keseluruhan dari matriks kovarians.



3

Teorema Naïve Bayes

- ✓ Sebelum menjelaskan **Naïve Bayes Classifier** ini, akan dijelaskan terlebih dahulu **Teorema Bayes** yang menjadi dasar dari metoda tersebut.
- ✓ Pada **Teorema Bayes**, bila terdapat dua kejadian yang terpisah (misalkan X dan H), maka **Teorema Bayes** dirumuskan sebagai berikut (**Bustami 2013**).

$$P(H|X) = \frac{P(X|H)}{P(X)} \cdot P(H)$$

Keterangan

- X : Data dengan *class* yang belum diketahui
 H : Hipotesis data merupakan suatu *class* spesifik
 P(H|X) : Probabilitas hipotesis H berdasar kondisi X (*posteriori probabilitas*)
 P(H) : Probabilitas hipotesis H (*prior probabilitas*)
 P(X|H) : Probabilitas X berdasarkan kondisi pada hipotesis H
 P(X) : Probabilitas X



4


Teorema Naïve Bayes

- ✓ **Teorema Bayes** sering pula dikembangkan mengingat berlakunya hukum probabilitas total, menjadi seperti berikut:

$$P(H|X) = \frac{P(X|H)}{\sum_{i=1}^n P(H_i|X)} \cdot P(H)$$

Keterangan


- $i : 1, 2, 3, \dots, n$ jumlah data Hipotesis (*prior probabilitas*)
- dimana : $H_1 \cup H_2 \cup H_3 \dots \cup H_n = S$
- S : Probabilitas total H



Teorema Naïve Bayes

- ✓ Untuk menjelaskan **Teorema Naïve Bayes**, perlu diketahui bahwa proses klasifikasi memerlukan sejumlah petunjuk untuk menentukan kelas apa yang cocok bagi *sampel* yang dianalisis tersebut.
- ✓ Karena itu, **Teorema Bayes** di atas disesuaikan sebagai berikut:

$$P(C|F_1, \dots, F_n) = \frac{P(F_1, \dots, F_n|C)}{P(F_1, \dots, F_n)} \cdot P(C)$$




Teorema Naïve Bayes

- ✓ Di mana **Variabel C** merepresentasikan kelas, sementara variabel $F_1 \dots F_n$ merepresentasikan karakteristik petunjuk yang dibutuhkan untuk melakukan klasifikasi.
- ✓ Maka rumus tersebut menjelaskan bahwa peluang masuknya sampel karakteristik tertentu dalam kelas C (*Posterior*) adalah peluang munculnya kelas C (sebelum masuknya *sampel* tersebut, seringkali disebut *prior*), dikali dengan peluang kemunculan karakteristik-karakteristik *sampel* pada kelas C (disebut juga *likelihood*), dibagi dengan peluang kemunculan karakteristik-karakteristik *sampel* secara global (disebut juga *evidence*). Karena itu, rumus di atas dapat pula ditulis secara sederhana sebagai berikut:

$$\text{Posterior} = \frac{\text{prior} \times \text{likelihood}}{\text{evidence}}$$

- ✓ Nilai *Evidence* selalu tetap untuk setiap kelas pada satu *sampel*. Nilai dari *posterior* tersebut nantinya akan dibandingkan dengan nilai-nilai posterior kelas lainnya untuk menentukan ke kelas apa suatu *sampel* akan diklasifikasikan.



Alur Metode Naive Bayes

Tahapan metode Naive Bayes adalah sebagai berikut:

1. Membaca Data Training
2. Menghitung Jumlah dan Probabilitas, namun jika data numerik maka
 - a) Menghitung nilai *mean* dan Dtandar Deviasi dari masing-masing parameter yang merupakan numerik. Adapun persamaan untuk mencari nilai rata-rata hitung (*mean*) adalah seperti dalam persamaan berikut :


$$\mu = \frac{\sum_{i=1}^n x_i}{n}$$

atau

$$\mu = \frac{x_1 + x_2 + x_3 + \dots + x_n}{n}$$

Keterangan

- μ : nilai rata-rata hitung (mean)
- x_i : nilai x ke-i
- n : jumlah sampel



Alur Metode Naive Bayes

Tahapan metode Naive Bayes adalah sebagai berikut:

Sedangkan persamaan untuk menghitung nilai Nilai Simpangan Baku (Standar Deviasi) dirumuskan sebagai berikut :

$$\sigma = \sqrt{\frac{\sum_{i=1}^n (x_i - \mu)^2}{n - 1}}$$

Keterangan

- σ : standar deviasi
- x_i : nilai x ke-i
- μ : nilai rata-rata hitung (mean)
- n : jumlah sampel

- b) Menghitung nilai probabilistik dengan cara menghitung jumlah data yang sesuai dari kategori yang sama dibagi dengan jumlah data pada kategori tersebut
3. Mendapatkan nilai dalam tabel mean, Standar Deviasi dan Probabilitas
4. Menghasilkan Solusi

9

Kelebihan dan Kekurangan

“ Teorema Naïve Bayes memiliki beberapa kelebihan dan kekurangan sebagai berikut:

Teori Bayesian, mempunyai beberapa **kelebihan** (Grainner 1998), yaitu:

- Mudah untuk dipahami
- Hanya memerlukan pengkodean yang sederhana
- Lebih cepat dalam penghitungan
- Menangani kuantitatif dan data diskrit
- Kokoh untuk titik noise yang diisolasi, misalkan titik yang dirata – ratakan ketika mengestimasi peluang bersyarat data.
- Hanya memerlukan sejumlah kecil data pelatihan untuk mengestimasi parameter (rata – rata dan variansi dari variabel) yang dibutuhkan untuk klasifikasi.
- Menangani nilai yang hilang dengan mengabaikan instansi selama perhitungan estimasi peluang
- Cepat dan efisiensi ruang
- Kokoh terhadap atribut yang tidak relevan

K
E
L
E
B
I
H
A
N

10

Kelebihan dan Kekurangan



Teorema Naïve Bayes memiliki beberapa kelebihan dan kekurangan sebagai berikut:

K E K U R A N G A N

Sedangkan **kekurangan** dari Teorema ini adalah :

- Kekurangan dari Teori probabilitas Bayesian yang banyak dikritisi oleh para ilmuwan adalah karena pada teori ini, satu probabilitas saja tidak bisa mengukur seberapa dalam tingkat keakuratannya. Dengan kata lain, kurang bukti untuk membuktikan kebenaran jawaban yang dihasilkan dari teori ini.
- Tidak berlaku jika probabilitas kondisionalnya adalah 0 (nol), apabila nol maka probabilitas prediksi akan bernilai nol juga
- Mengasumsikan variabel bebas



11

Laplace Correction

- **Laplace Correction (Laplacian Estimator)** atau **additive smoothing** adalah suatu cara untuk menangani nilai probabilitas 0 (nol) (Manning 2009).
- Dari sekian banyak data di training set, pada setiap perhitungan datanya ditambah 1 (satu) dan tidak akan membuat perbedaan yang berarti pada estimasi probabilitas sehingga bisa menghindari kasus nilai probabilitas 0 (nol).
- **Laplace Correction** ini dapat dinyatakan dalam persamaan seperti pada persamaan berikut ini

$$\rho_i = \frac{m_i + 1}{n + k}$$

Keterangan

ρ_i : probabilitas dari atribut m_i

m_i : jumlah sampel dalam kelas dari atribut m_i

k : jumlah kelas dari atribut m_i

n : jumlah sampel

Sebagai contoh, asumsikan ada **class Penggunaan Listrik=rendah** di suatu training set, memiliki 5 sampel, ada 1 sampel dengan **Daya Listrik=rendah**, 4 sampel dengan **Daya Listrik=sedang**, dan 0 sampel dengan **Daya Listrik=tinggi**.

12

Laplace Correction

- Sebagai contoh, asumsikan ada *class Penggunaan Listrik=rendah* di suatu training set, memiliki 5 sampel, ada 1 sampel dengan *Daya Listrik=rendah*, 4 sampel dengan *Daya Listrik=sedang*, dan 0 sampel dengan *Daya Listrik=tinggi*.
- Probabilitas dari kejadian ini **tanpa Laplacian Correction** adalah
 $P(\text{Daya Listrik}=\text{rendah} | \text{Penggunaan Listrik}=\text{rendah})=0.200$ (dari 1/5),
 $P(\text{Daya Listrik}=\text{sedang} | \text{Penggunaan Listrik}=\text{rendah})=0.800$ (dari 4/5), dan
 $P(\text{Daya Listrik}=\text{tinggi} | \text{Penggunaan Listrik}=\text{rendah})=0$.
- Menggunakan **Laplacian Correction** dari tiga kejadian diatas, diasumsikan ada 1 sampel lagi untuk masing – masing nilai *Penggunaan Listrik=rendah*. Dengan cara ini, didapatkanlah probabilitas sebagai berikut (dibulatkan menjadi 3 angka dibelakang koma):
 $P(\text{Daya Listrik}=\text{rendah} | \text{Penggunaan Listrik}=\text{rendah})=0.250$ (dari 2/8),
 $P(\text{Daya Listrik}=\text{sedang} | \text{Penggunaan Listrik}=\text{rendah})=0.625$ (dari 5/8), dan
 $P(\text{Daya Listrik}=\text{tinggi} | \text{Penggunaan Listrik}=\text{rendah})=0.125$ (dari 1/8)
- Probabilitas yang "*dibenarkan*" hasilnya tidak berbeda jauh dengan hasil probabilitas sebelumnya sehingga nilai probabilitas 0 (nol) dapat dihindari.

13

CONTOH KASUS DG NAÏVE BAYES

id	Age	income	student	Credit_rating	Class
1	<=30	High	No	Fair	No
2	<=30	High	No	Excellent	No
3	31.40	High	No	Fair	Yes
4	> 40	Medium	No	Fair	Yes
5	> 40	Low	Yes	Fair	Yes
6	> 40	Low	Yes	Excellent	No
7	31.40	Low	Yes	Excellent	Yes
8	<=30	Medium	No	Fair	No
9	<=30	Low	Yes	Fair	Yes
10	> 40	Medium	Yes	Fair	Yes
11	<=30	Medium	Yes	Excellent	Yes
12	31.40	Medium	No	Excellent	Yes
13	31.40	High	Yes	Fair	Yes
14	> 40	Medium	No	Excellent	no

Berikut adalah kasus dari AllElectronics untuk mengklasifikasikan apakah "buys_computer" yes or no. Di samping Data Training AllElectronics customer database . Misal terdapat data X (belum diketahui class nya)
 $X = (\text{age}=\text{"<=30"}, \text{income}=\text{"medium"}, \text{student}=\text{"yes"}, \text{credit_rating}=\text{"fair"})$

14

CONTOH KASUS DG NAÏVE BAYES

Penyelesaian :

Dibutuhkan untuk memaksimalkan $P(X|C_i) P(C_i)$ untuk $i= 1, 2$.

$P(C_i)$ merupakan *prior probability* untuk setiap class berdasar data contoh:

- $P(\text{buys_computer} = \text{"yes"}) = 9/14 = 0.643$
- $P(\text{buys_computer} = \text{"no"}) = 5/14 = 0.357$

Hitung $P(X|C_i)$, untuk $i=1,2$

- $P(\text{age} = \text{"<30"} | \text{buys_computer} = \text{"yes"}) = 2/9 = 0.222$
- $P(\text{age} = \text{"<30"} | \text{buys_computer} = \text{"no"}) = 3/5 = 0.600$

15

CONTOH KASUS DG NAÏVE BAYES

Penyelesaian :

- $P(\text{income} = \text{"medium"} | \text{buys_computer} = \text{"yes"}) = 4/9 = 0.444$
- $P(\text{income} = \text{"medium"} | \text{buys_computer} = \text{"no"}) = 2/5 = 0.400$
- $P(\text{student} = \text{"yes"} | \text{buys_computer} = \text{"yes"}) = 6/9 = 0.667$
- $P(\text{student} = \text{"yes"} | \text{buys_computer} = \text{"no"}) = 1/5 = 0.200$
- $P(\text{credit_rating} = \text{"fair"} | \text{buys_computer} = \text{"yes"}) = 6/9 = 0.667$
- $P(\text{credit_rating} = \text{"fair"} | \text{buys_computer} = \text{"no"}) = 2/5 = 0.400$

16

CONTOH KASUS DG NAÏVE BAYES

Penyelesaian :

- $P(X|\text{buys_computer}=\text{"yes"})$
 $= 0.222 \times 0.444 \times 0.677 \times 0.677 = 0.044$
- $P(X|\text{buys_computer}=\text{"no"})$
 $= 0.600 \times 0.400 \times 0.200 \times 0.400 = 0.019$
- $P(X|\text{buys_computer}=\text{"yes"}) P(\text{buys_computer}=\text{"yes"})$
 $= 0.044 \times 0.643 = 0.028$
- $P(X|\text{buys_computer}=\text{"no"}) P(\text{buys_computer}=\text{"no"})$
 $= 0.019 \times 0.357 = 0.007$

Kesimpulan: buys_computer = "yes"

17

LATIHAN SOAL NAÏVE BAYES

NO	JENIS KELAMIN	KTM	STATUS NIKAH	IPK	LULUS
1	L	MHS	TIDAK	3.17	TEPAT
2	L	KERJA	TIDAK	3.3	TEPAT
3	P	MHS	TIDAK	3.01	TEPAT
4	P	MHS	NIKAH	3.25	TEPAT
5	L	KERJA	NIKAH	3.2	TEPAT
6	L	KERJA	NIKAH	3.5	TERLAMBAT
7	P	KERJA	NIKAH	3	TERLAMBAT
8	P	KERJA	TIDAK	2.7	TERLAMBAT
9	L	KERJA	TIDAK	2.4	TERLAMBAT
10	P	MHS	NIKAH	2.5	TERLAMBAT
11	P	MHS	TIDAK	2.5	TERLAMBAT
12	P	MHS	TIDAK	3.5	TEPAT
13	L	KERJA	NIKAH	3.3	TEPAT
14	L	MHS	NIKAH	3.25	TEPAT
15	L	MHS	TIDAK	2.3	TERLAMBAT

DATA TESTING :

Jenis Kelamin	KTM	STATUS NIKAH	IPK	LULUS
L	MHS	TIDAK	2.7	???

BAGAIMANA HASIL DARI DATA UJI DIATAS ?!!!!

18